

Community Forensics-Small과 SID-Set을 활용한 소셜 미디어 강건형 경량 멀티헤드 이미지 포렌식 시스템

기존 real/fake 분류를 넘어 3-way 판별 + 조작 위치 추정 + 생성 계열 식별 + 근거 설명

목표: 소셜 미디어 유통 환경에 가까운 연구용 경량 포렌식 프로토타입

가반 | 6팀 | 김선재

BUSINESS PROPOSAL

문제 제기



1 생성형 AI로 사실적인 이미지 생성 및 조작이 쉬워짐

2 게시물 공유 과정에서 재압축, 스크린샷, 오버레이가 추가됨

3 허위정보, 상품 사기, 사칭 게시물로 악용될 수 있음

4 단순 real/fake가 아니라 어디가, 왜, 어떤 생성 계열인가를 함께 알려주는 포렌식이 필요

사례: 대전 오월드 늑대 탈출 당시 SNS·제보 경로로 확산된 출처 불명·AI 합성 의심 이미지
이미지 출처: 인스타그램 code_z_mag 편집본 / 사실관계 참고: 중앙일보, KBS, 동아일보

기존 연구와 한계

Community Forencis

4803개 생성기 2.7M 이미지

강점

- 다양한 생성기 학습을 통해 unseen generator 일반화 성능 향상
- 강한 분류 backbone과 perturbation-aware 학습 전략

한계

- 지원 과제는 이미지 분류 중심
- 조작 위치와 생성 계열 정보는 직접 제공하지 않음

SIDA

SID-Set 300K | 3-way + Mask + 설명

강점

- real / synthetic / tampered와 3-way 판별 제시
- tampered localization과 explanation까지 포함한 풍부한 문제 설정

한계

- 공개 구현 기준 LISA-7B/13B, SAM ViT-H 사용
- 단일 GPU 학기 프로젝트로 그대로 재현하기에는 구조가 무거움

필요한 방향 : 일반화 성능 + 3-way / localization 출력 + 경량화 + 소셜 미디어 강건성

프로젝트 목표와 핵심 아이디어

가져오는 것

Community Forensics-Small

- 다양한 생성기 기반 backbone 학습
- unseen generator generalization 강화
- architecture / model_name / subset metadata 활용

SIDA / SID-Set

- real / synthetic / tampered 3-way 설정
- tampered localization
- explanation 문제 설정

내가 추가하는 것

경량 멀티헤드 재구성

shared backbone + class head +
provenance head + conditional localization

소셜 미디어 특화 변형

screenshot / text overlay / sticker overlay /
recompression chain

템플릿 기반 설명

free-form LLM 대신 evidence template 사용

coarse provenance

exact model attribution 대신
architecture 기반 family-level 분류

최종 목표

연구용 포렌식 리포트

Class

Real / Synthetic /
Tampered

Famliy

LatDiff/PixDiff/GAN/
Other / N/A

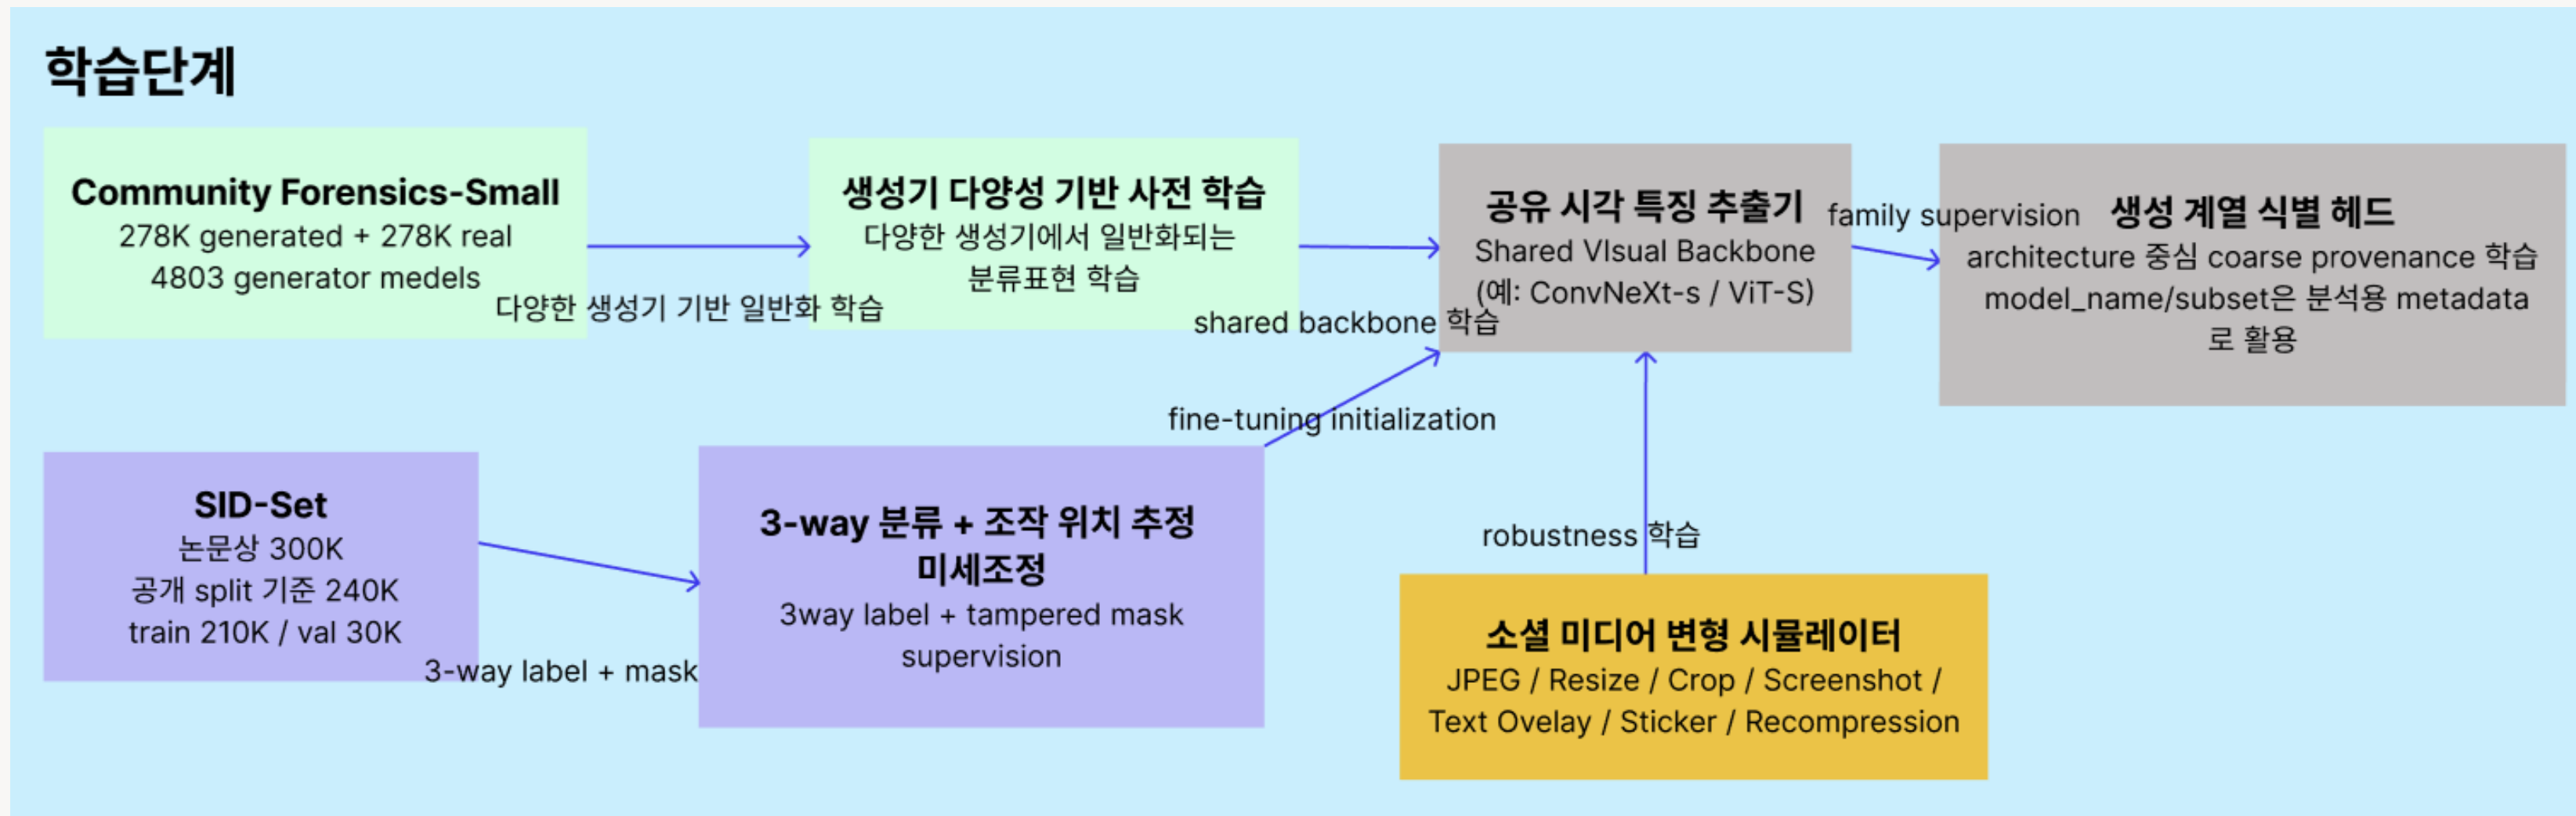
Mask

조작 의심 영역 시각화

Reason

근거 기반 짧은 설명

시스템 전체 구조 (1) : 학습 단계

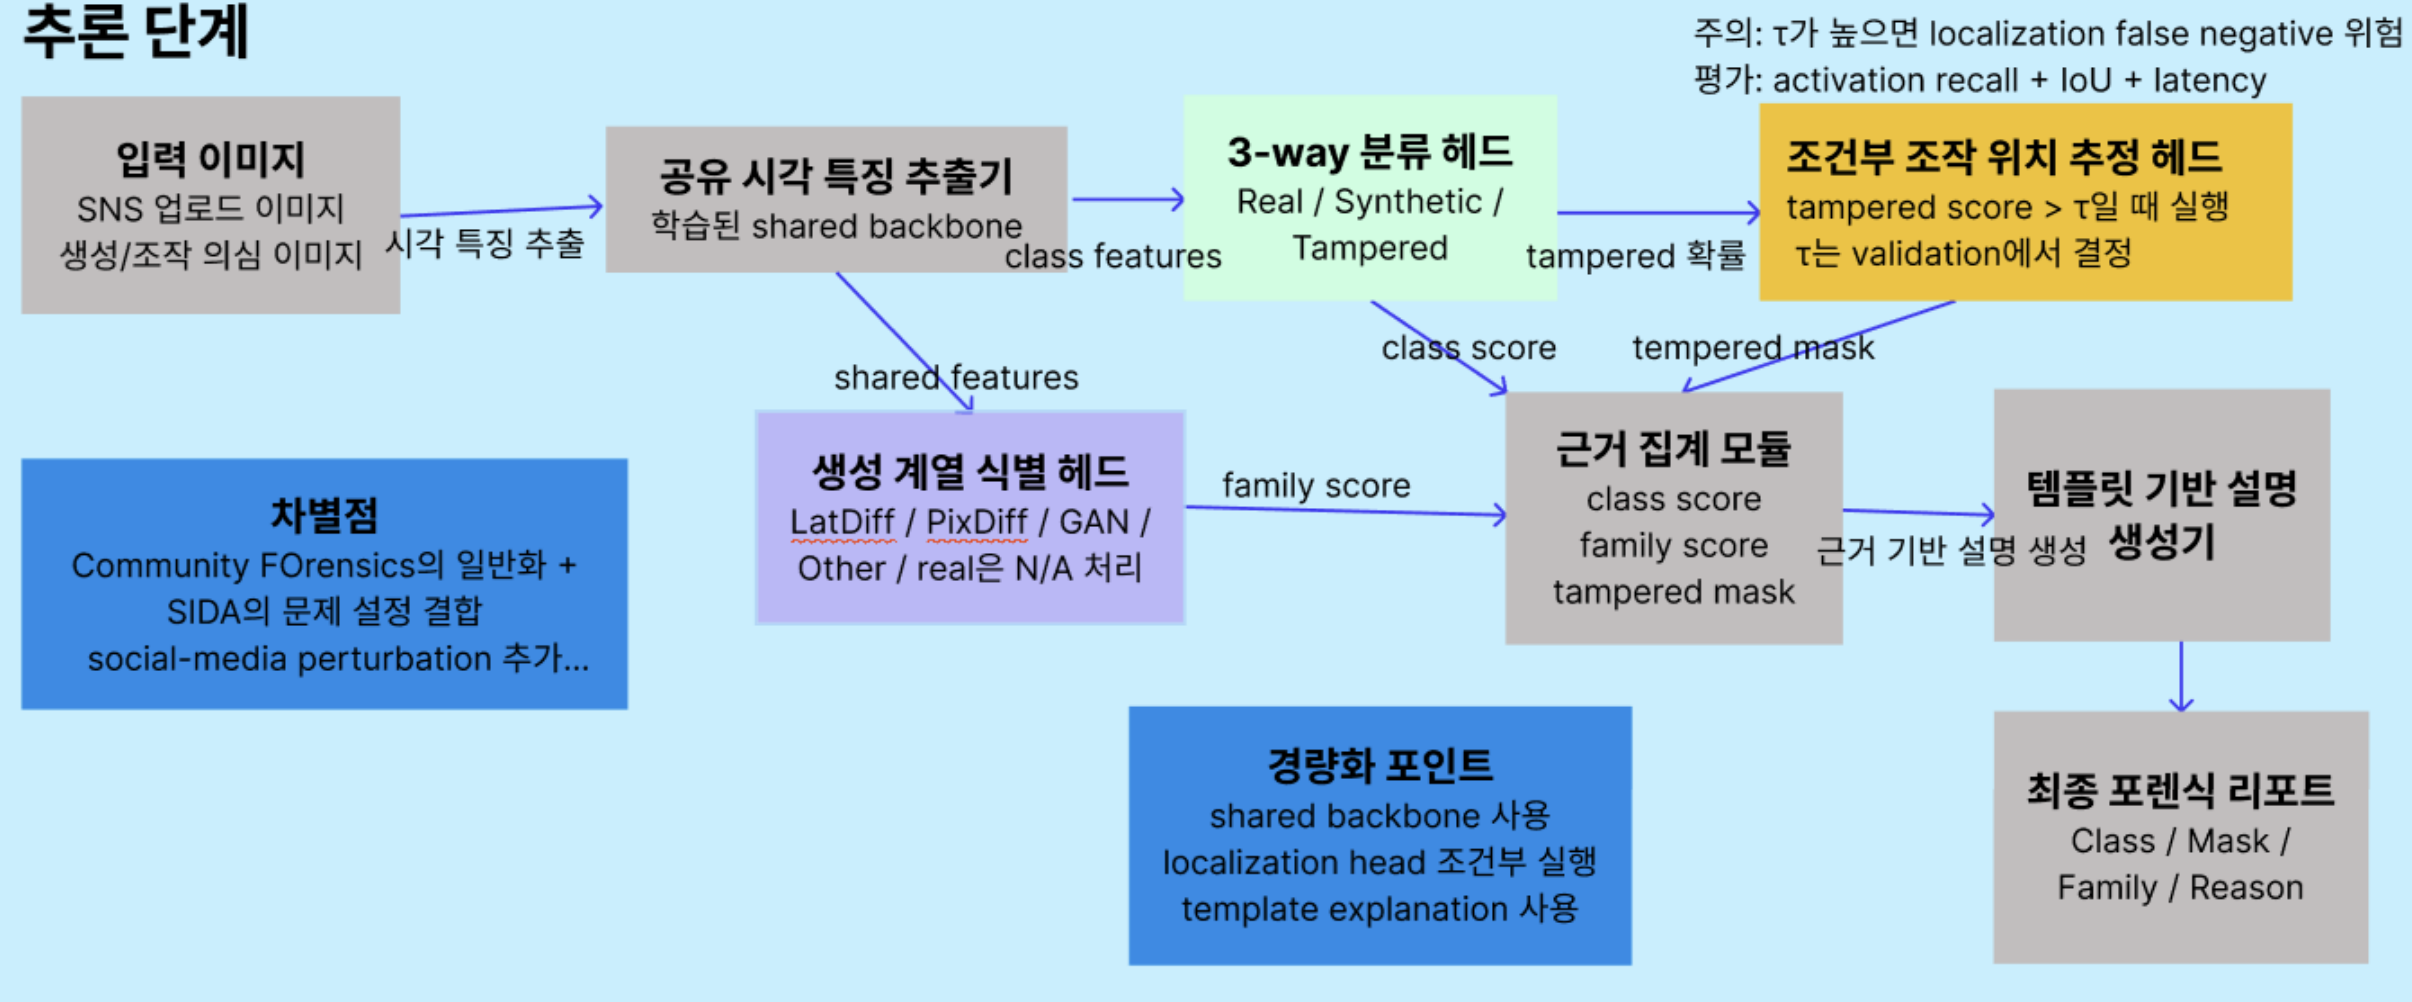


- Community Forensics-Small로 다양한 생성기에서 일반화되는 shared backbone을 사전 학습
- architecture 중심 metadata를 활용해 generator-family provenance head 학습
※ model_name / subset은 분석용 metadata로 활용
- SID-Set의 3-way label과 tampered mask를 이용해 multi-head fine-tuning 수행
- social-media perturbation을 추가해 실제 플랫폼 유통 환경에 대한 robustness 강화

핵심: 생성기 다양성 기반 일반화 backbone을 만들고, SID-Set과 social-media perturbation으로 실제 포렌식 문제에 맞게 미세조정한다.

시스템 전체 구조 (2) : 추론 단계


추론 단계



- 입력 이미지는 shared backbone을 통해 공통 시각 특징으로 변환됨
- 3-way classification과 provenance head는 기본적으로 실행됨
- tampered 확률이 높을 때만 localization head를 조건부로 활성화하여 조작 의심 영역 예측
- class score, family score, tampered mask를 evidence aggregation module에서 통합하고, template-based explanation을 통해 최종 포렌식 리포트 생성

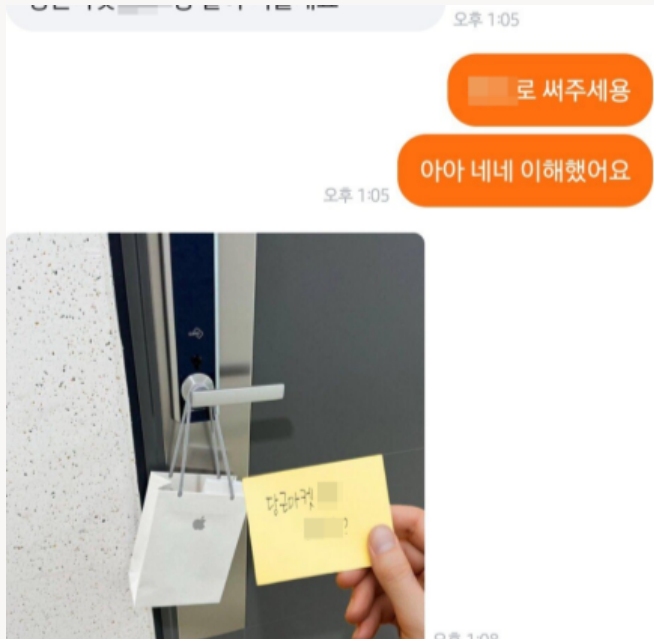
핵심: 필요한 경우에만 localization을 수행하는 조건부 추론 구조로 연산량을 줄이고, Class / Mask / Family / Reason을 함께 제공한다.

소셜 미디어 특화 변형



Original

기준 입력 예시



Screenshot

화면 캡처로 인한
padding / resampling



Text Overlay

영자막, 판매문구, 배너가
artifact와 경계를 가릴 수 있음



Sticker Overlay

이모지, 스티커가 일부 영역을
가려 localization을 어렵게 함



Recompression

업로드, 재공유 과정의
연쇄 저장/압축을 모사

왜 추가하는가?
Community Forensics와 SIDA는 JPEG, resize, crop, Gaussian noise와 같은 기본 변형 강건성을 다루지만, 실제 소셜 미디어에서는 screenshot, text overlay, sticker overlay, recompression chain이 자주 발생한다. 따라서 플랫폼 유통 후의 실제 분포에 가까운 robustness 학습이 필요하다.

경량화는 어떻게 진행하는가?

대형 구조(직접 재현 시)

LISA 기반 LMM + SAM 기반 vision 구조
classification / localization /
explanation 포함

연산량 **높음**

메모리 요구 **높음**

문제

- 단일 GPU 학기 프로젝트에 부담
- 설명 생성까지 포함하면 구현 비용 증가
- 구조는 풍부하지만 재현 난이도가 높음

compression이 아니라
redesign 관점의 경량화

경량구조

1) Shared Backbone

classification / provenance / localization이 하나의
backbone을 공유

2) Conditional Localization

tampered score가 높을 때만 localization 수행


3) Template Explanation

자유 문장 생성 대신 근거 템플릿 설명 사용

4) Coarse Provenance

exact model attribution 대신 family-level 분류 사용

구현 단계와 평가 계획



평가 항목	설명
3-way Classification Accuracy / Macro-F1	Real / Synthetic / Tampered 3분류 성능. Accuracy는 전체 정답률, Macro-F1은 클래스별 균형 성능 평가
Tampered Mask IoU	Tampered 이미지에서 예측 마스크와 정답 마스크의 겹침 정도. 조작 위치 추정 성능 평가
Generator-Family Accuracy	LatDiff / PixDiff / GAN / Other 등 generator family 기준 coarse provenance 정확도
Perturbation Robustness Drop ($\Delta F1$ / ΔIoU)	Screenshot / Text Overlay / Sticker / Recompression 적용 전후 성능 차이. 값이 작을수록 강건함
Latency (ms/img, FPS)	RTX 4090, batch size 1 기준 평균 추론 시간(ms/img) 및 FPS 측정
Localization Activation Recall	실제 tampered 이미지 중 localization head가 활성화된 비율. threshold τ 로 인한 false negative 위험 평가

기대 결과와 최종 출력

입력 이미지



Input / mask visualization adapted from SIDA GitHub README example.
Right panel shows expected output mock-up, not an actual model prediction.

조작 의심 영역 시각화

tampered 확률이 높을 때 localization head 활성화



"mask_area_pct": 11.2,
"localization_head": "activated
(tampered_score 0.89 > τ_{val})"

예상 출력 예시

Class

```
"class": "tampered",  
"class_conf": {"real": 0.03, "synthetic": 0.08, "tampered": 0.89}
```

Family

```
"family": "LatDiff",  
"family_conf": {"LatDiff": 0.78, "PixDiff": 0.14, "GAN": 0.05,  
"Other": 0.03},
```

Reason (evidence template)

"reason": "국부 경계 불연속성과 텍스처 불일치가 관찰됨. Family
분류는 LatDiff 우세."

요약

Tampered 이미지로 판단, 중앙 부분 영역 조작 의심

결론 및 향후 과제

프로젝트 핵심 요약

Generalization
Community Forensics-Small 기반
shared backbone 학습

Multi-task
3-way 분류 + tampered localization

Robustness
social-media perturbation (screenshot
/ overlay / recompression

Lightweight
conditional localization + template
explanation + family-level provenance

Prototype
Class / Mask / Family / Reason을 제공
하는 실용적 포렌식 시스템

향후 과제

Exact Attribution
generator family를 넘어 exact model
attribution으로 확장

Richer Explanation
template explanation에서 더 풍부한
자연어 설명으로 확장

Watermark + Provenance
content-based forensics와 워터마크 기
반 provenance 신호 결합

In-the-wild Benchmark
실제 업로드 이미지와 플랫폼 분포에서
일반화 성능을 추가 검증

참고 문헌

Huang, Z. et al., "SIDA: Social Media Image Deepfake Detection, Localization and Explanation with Large Multimodal Model," CVPR 2025.

Park, J. and Owens, A., "Community Forensics: Using Thousands of Generators to Train Fake Image Detectors," CVPR 2025.

OwensLab, "CommunityForensics-Small Dataset Card," Hugging Face.

hzlsaber, "SIDA GitHub Repository README," GitHub.

FTC, "FTC Proposes New Protections to Combat AI Impersonation of Individuals," 2024.

FTC, "FTC Announces Impersonation Rule Goes into Effect Today," 2024.

인스타그램 code_z_mag 편집이미지

중앙일보 / KBS / 동아일보 대전 오월드 늑대 탈출 관련 AI 허위 제보 기사

발표를 들어주셔서
감사합니다.

THANK YOU