

## 1. 주제

Community Forensics-Small과 SID-Set을 활용한 소셜 미디어 강건형 경량 멀티헤드 이미지 포렌식 시스템

가반, 6팀, 김선재

## 2. 요약

본 프로젝트는 소셜 미디어에 유통되는 AI 생성 및 조작 이미지를 판별하기 위한 연구용 경량 멀티헤드 이미지 포렌식 프로토타입을 제안한다. Community Forensics-Small을 이용해 다양한 생성기에 일반화되는 shared backbone 후보를 학습하고, SID-Set을 이용해 real / synthetic / tampered 3-way 분류와 tampered mask localization을 결합한다. 또한 screenshot, text overlay, sticker overlay, recompression chain과 같은 소셜 미디어 변형을 후보 augmentation으로 추가해 플랫폼 유통 환경에 대한 강건성을 평가한다. 생성 계열 식별은 정확한 모델명을 맞히는 exact model attribution이 아니라 Community Forensics-Small의 architecture metadata를 활용한 coarse provenance task로 제한한다. 초기 label 후보는 LatDiff / PixDiff / GAN / Other / Real-or-N/A이며, model\_name과 subset은 label 세분화 여부를 판단하기 위한 분석용 metadata로 사용한다. 최종 backbone, family label 구성, loss 적용 방식은 제안 발표 이후 데이터 분포와 실험 환경을 확인해 확정한다.

## 3. 대표 그림



이 그림은 왼쪽에서 문제 배경, 가운데에서 기존 연구와 한계, 오른쪽에서 제안 시스템의 결과 형태를 보여주도록 구성했다. Community Forensics는 생성기 다양성 기반 일반화 강점을, SIDA는 3-way 판별·위치 추정·설명 문제 설정을 보여주지만, 각각 분류 중심과 대형 구조라는 한계를 가진다. 제안 시스템은 이들의 장점을 결합해 class, mask, family, reason을 함께 출력하는 연구용 경량 포렌식 프로토타입을 목표로 한다.

## 4. 서론


배경 설명 및 사례 분석. 생성형 AI의 발전으로 사실적인 이미지를 매우 쉽게 만들거나 부분적으로 조작

할 수 있게 되면서, 온라인 환경에서 이미지의 신뢰성을 검증하는 문제는 점점 더 중요해지고 있다. 특히 소셜 미디어 환경에서는 생성 이미지가 허위 정보, 상품 사기, 유명인 또는 일반인 사칭, 조작된 증거 이미지 유포와 결합될 수 있어 사회적 피해 가능성이 크다. 미국 FTC는 2024년 AI-generated deepfakes가 impersonation fraud를 가할 수 있다고 밝히며, 개인 사칭까지 포함하는 추가 보호 조치를 제안했고, 이어 2024년 4월에는 정부·기업 사칭 관련 규칙 시행과 함께 사칭 사기로 인한 피해 규모를 강조했다 [4][5]. 이러한 배경은 단순한 “딥페이크 탐지”를 넘어, 실제 플랫폼 환경에서 조작 여부와 근거를 함께 제시하는 포렌식 기술의 필요성을 보여준다.

문제 정의. 기존 AI 이미지 포렌식 연구에는 두 가지 큰 한계가 있다. 첫째, 많은 연구가 여전히 binary real/fake 분류에 초점을 두고 있어, 사용자가 실제로 궁금해하는 “어디가 조작되었는가”, “어떤 생성 계열일 가능성이 높는가”에 답하지 못한다. 둘째, 실제 소셜 미디어 환경에서 흔히 발생하는 재압축, 크기 변경, 잘라내기, 스크린샷, 텍스트 오버레이와 같은 후처리 조건을 충분히 반영하지 못하는 경우가 많다. Community Forensics는 4,803개 생성기와 2.7M 이미지로 일반화 성능을 크게 향상시켰고 JPEG, resizing, cropping, rotation, shear, padding 등의 변형 강건성도 분석했지만, supported task는 기본적으로 이미지 분류다 [1]. 반면 SIDA는 social-media용 SID-Set을 통해 3-way 분류와 tampered region localization, explanation까지 제안했지만, 공개 저장소 기준 LISA-7B/13B 및 SAM ViT-H를 사용한다 [2][6]. 따라서 본 프로젝트는 “단일 GPU 환경에서 구현 가능한 경량 구조로, social-media 변형에 강하고, 탐지·위치 추정·생성 계열 식별을 함께 수행하는 연구용 이미지 포렌식 프로토타입”을 문제로 정의한다.

극복 방안. 본 연구는 위 한계를 극복하기 위해 두 기존 방향을 결합한 경량 멀티헤드 포렌식 시스템을 제안한다. 먼저 Community Forensics-Small을 이용하여 다양한 생성기에서 일반화되는 shared backbone을 학습하고, SID-Set을 이용하여 real / synthetic / tampered의 3-way 분류와 tampered mask 예측을 결합한다 [2][3]. 여기에 Community Forensics-Small이 제공하는 architecture, model\_name, subset 메타데이터를 활용한 생성 계열 식별 head를 추가하고, 기존 변형 강건성 학습에 screenshot, text overlay, sticker overlay와 같은 소셜 미디어 특화 변형을 확장한다 [1][3]. 마지막으로 explanation은 대형 언어모델을 그대로 재현하기보다, 분류 결과, 마스크, 생성 계열 추정 결과를 바탕으로 한 lightweight evidence template 방식으로 구현하여 단일 GPU 환경에서도 구현 가능한 연구용 경량 프로토타입을 목표로 한다.

## 5. 본론




시스템 개요. 학습 단계에서는 Community Forensics-Small을 이용해 다양한 생성기에서 일반화되는 공유

시각 특징 추출기를 후보 backbone으로 학습한다. generator-family provenance는 정확한 모델명을 맞히는 exact model attribution이 아니라, Community Forensics-Small의 architecture 메타데이터를 활용한 coarse provenance task로 정의한다. 초기 label 후보는 LatDiff / PixDiff / GAN / Other / Real-or-N/A이며, model\_name과 subset은 label 세분화 여부를 판단하기 위한 분석용 메타데이터로 사용한다. 이후 SID-Set으로 real / synthetic / tampered의 3-way classification과 tampered mask localization을 결합한 멀티헤드 구조를 fine-tuning한다. 이때 SID-Set 샘플에는 동일한 family label이 없을 수 있으므로, 기본안에서는 provenance head를 고정하거나 SID-Set 샘플에 대해 family loss를 적용하지 않는다. 대안으로는 Community Forensics-Small mini-batch를 일부 섞어 provenance loss를 보조적으로 유지하는 방식을 비교한다. 추론 단계에서는 3-way classification head와 provenance head를 먼저 실행하고, tampered score가 validation set에서 정한 threshold  $\tau$ 를 넘는 경우에만 conditional localization head를 활성화한다. 단,  $\tau$ 가 높으면 tampered 이미지를 놓쳐 localization이 실행되지 않는 false negative 위험이 있으므로,  $\tau$ 는 tampered recall을 우선 고려해 결정하고 threshold별 성능·연산량 trade-off를 함께 평가한다.

### 예시 추론 단계

입력 이미지 1장에 대해 class / family / mask / reason을 생성하는 전체 흐름



단, 그림의 class score, family score, mask 결과는 제안 시스템의 목표 출력 형식을 설명하기 위한 예시값이며, 실제 학습 완료 모델의 확정 예측 결과가 아니다.

필요한 기술 요소. 본 시스템 구현에는 강건한 이미지 분류 backbone, 3-way classification, tampered localization, generator-family provenance prediction, social-media perturbation robustness, template-based explanation의 여섯 요소가 필요하다. backbone은 Community Forensics-Small의 데이터 다양성을 활용해 학습하고, provenance head는 architecture 중심 label을 사용하되 model\_name과 subset은 분석용 metadata로 활용한다 [3]. localization은 SID-Set의 tampered mask를 이용해 학습하며, 설명 모듈은 자유 문장 생성 대신 evidence template를 사용해 경량화를 달성한다 [2][6]. 평가 시에는 3-way classification Accuracy/Macro-F1, tampered mask IoU, generator-family accuracy, perturbation 전후 성능 저하량, localization activation recall, 그리고 RTX 4090 환경에서의 추론 시간과 FPS를 함께 측정한다. 데이터 저장 공간 부담을 줄이기 위해 초기 실험은 streaming 또는 subset sampling으로 진행하고, 최종 실험에서 전체 train split과 별도 evaluation set으로 확장한다.

구현 방법 및 개발 방향. 구현은 총 네 단계로 진행한다. 1단계에서는 Community Forensics-Small을 이용하여 ConvNeXt-S 또는 CLIP-ViT-S 계열 후보 backbone 기반의 binary detector를 재현하고, Community Forensics 논문에서 사용한 JPEG, resize, crop, rotation, padding, shear 등의 기본 변형을 먼저 반영한다 [1]. Community Forensics-Small은 공개 dataset card 기준 기본 train split 중심으로 제공되므로, 검증은 train 내부에서 generator 또는 model\_name 단위 hold-out을 구성하거나 CommunityForensics-Eval의

CompEval split을 별도 evaluation set으로 사용하는 방식을 비교한다. 특히 본 프로젝트의 핵심이 unseen generator 일반화이므로, 단순 random split보다 generator-holdout validation을 우선 고려한다. 2단계에서는 동일 backbone 위에 generator-family provenance head를 추가하여 architecture metadata 기반의 coarse provenance 분류를 수행한다 [3]. 3단계에서는 SID-Set으로 fine-tuning하여 real / synthetic / tampered의 3-way classification과 tampered mask localization을 함께 학습한다. SID-Set은 논문상 300K 규모로 제안되었지만, 본 프로젝트의 초기 구현은 현재 공개 split 기준 train 210K, validation 30K의 240K rows를 우선 사용한다. 이때 full SIDA 구조를 그대로 재현하는 대신, 대형 VLM 대신 shared visual backbone과 경량 decoder를 사용하는 multi-head 구조로 단순화한다 [2][6]. 또한 SID-Set 샘플에는 Community Forensics-Small과 동일한 generator-family label이 없을 수 있으므로, 기본안에서는 provenance head를 고정하거나 SID-Set 샘플에 대해 family loss를 mask-out한다. 대안으로는 Community Forensics-Small mini-batch를 일부 함께 섞어 provenance loss를 보조적으로 유지하는 multi-dataset fine-tuning을 비교한다. 4단계에서는 screenshot, text overlay, sticker overlay, recompression chain과 같은 social-media perturbation을 추가하여 robustness를 강화하고, 최종적으로 분류 결과, mask, provenance 예측을 종합해 짧은 evidence template 설명을 출력한다.

## 6. 결론

본 프로젝트는 Community Forensics의 diversity-driven generalization과 SIDA의 detection / localization / explanation 문제 설정을 결합하여, 소셜 미디어 환경에 적합한 연구용 경량 포렌식 프로토타입을 제안한다 [1][2]. 제안 시스템은 단순 real/fake 판정을 넘어 real / synthetic / tampered 분류, 조작 위치 추정, 생성 계열 식별, 간단한 근거 설명을 동시에 제공하는 것을 목표로 한다. 특히 screenshot, text overlay, sticker overlay와 같은 social-media perturbation을 별도 평가 조건으로 추가하여 실제 사용 환경에 더 가까운 강건성을 확보하고자 한다. 향후에는 exact model attribution, 보다 풍부한 자연어 설명, 그리고 워터마크 기반 provenance 신호를 결합하는 방향으로 확장할 수 있다.

## 7. 출처

[1] J. Park and A. Owens, "Community Forensics: Using Thousands of Generators to Train Fake Image Detectors," Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2025.

[2] Z. Huang, J. Hu, X. Li, Y. He, X. Zhao, B. Peng, B. Wu, X. Huang, and G. Cheng, "SIDA: Social Media Image Deepfake Detection, Localization and Explanation with Large Multimodal Model," Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2025. (메인 주제)

[3] OwensLab, "CommunityForensics-Small Dataset Card," Hugging Face Datasets, accessed Apr. 11, 2026.

[4] Federal Trade Commission, "FTC Proposes New Protections to Combat AI Impersonation of Individuals," Press Release, Feb. 15, 2024.

[5] Federal Trade Commission, "FTC Announces Impersonation Rule Goes into Effect Today," Press Release, Apr. 1, 2024.

[6] hzlsaber, "SIDA GitHub Repository README," GitHub, accessed Apr. 11, 2026.